

GeoFormerDock: Kiến trúc học sâu đa nhiệm khai thác thông tin hình học cho bài toán liên kết protein – phối tử

Nguyễn Minh Đức*, Đào Duy Phát[†], Đặng Trí Hiếu[†],
Hà Vũ Minh Đức*, Tạ Văn Nhân*, Nguyễn Thị Hồng Minh*
*Trường Đại học Khoa học Tự nhiên, Đại học Quốc gia Hà Nội,
[†]Trường Quốc tế, Đại học Quốc gia Hà Nội

Email: ducnm160704@gmail.com, daoduyphat066@gmail.com, trihieu666@gmail.com,
minhduc5clhp@gmail.com, tavannhan@gmail.com, minhnhth@hus.edu.vn

Tóm tắt nội dung – Trong thiết kế thuốc dựa trên cấu trúc, mô phỏng liên kết protein và phối tử đóng vai trò quan trọng trong đánh giá và sàng lọc các hợp chất tiềm năng. Việc tối ưu đồng thời hai mục tiêu là phân loại tư thế gắn kết và dự đoán ái lực liên kết thường dẫn đến sự đánh đổi về mặt hiệu năng. Bên cạnh đó, sự thiếu đồng nhất trong thiết lập huấn luyện cùng vấn đề mất cân bằng lớp của dữ liệu làm giảm độ tin cậy khi đánh giá các mô hình. Nghiên cứu này đề xuất GeoFormerDock, một kiến trúc học sâu đa nhiệm trên biểu diễn lưới voxel 3D, kết hợp mạng tích chập 3D, đặc trưng hình học tường minh cho nhánh phân loại tư thế và cơ chế thiên vị chú ý theo khóa cho nhánh dự đoán ái lực. Đồng thời, nghiên cứu xây dựng một khung đánh giá chung cho bốn mô hình học sâu, tích hợp chiến lược lấy mẫu cân bằng lớp ở mức minibatch. Kết quả thực nghiệm cho thấy GeoFormerDock đạt vị trí không bị trội khi xét đồng thời hai nhiệm vụ, và thể hiện ưu thế rõ rệt ở nhiệm vụ phân loại tư thế với Balanced Accuracy và PR-AUC cao nhất trong các mô hình so sánh, trong khi quy mô tham số nhỏ hơn đáng kể so với các kiến trúc CNN chuyên biệt. Ở nhiệm vụ dự đoán ái lực, GeoFormerDock vẫn thấp hơn baseline mạnh nhất, với khác biệt có ý nghĩa thống kê trên cả năm chỉ số. So với hai baseline còn lại, chưa đủ bằng chứng thống kê để kết luận khác biệt ở các chỉ số tương quan và xếp hạng (Pearson, Spearman, C-index). Các kết quả cho thấy GeoFormerDock cung cấp một điểm đánh đổi đáng chú ý giữa hai nhiệm vụ. Khung đánh giá thống nhất cho phép so sánh khách quan các kiến trúc trong cùng điều kiện dữ liệu và huấn luyện.

Từ khóa – Liên kết protein–phối tử, phân loại tư thế gắn kết, dự đoán ái lực liên kết, học đa nhiệm, mạng tích chập 3D, cơ chế chú ý, thiết kế thuốc dựa trên cấu trúc.

I. MỞ ĐẦU

Mô phỏng liên kết protein–phối tử là một bước tính toán then chốt trong thiết kế thuốc dựa trên cấu trúc, cho phép đánh giá khả năng gắn kết của các

hợp chất trước khi tiến hành thực nghiệm [1], [2]. Hai nhiệm vụ cốt lõi trong quá trình này là phân loại tư thế gắn kết và dự đoán ái lực liên kết [3], [4]. Mặc dù các phương pháp học sâu trên không gian 3D đã mang lại nhiều cải tiến [5], [6], hiệu năng của các mô hình hiện có thường không đồng đều giữa hai nhiệm vụ. Bên cạnh đó, tình trạng mất cân bằng nghiêm trọng giữa tư thế tốt và tư thế nhiễu trong dữ liệu huấn luyện tiếp tục gây khó khăn cho việc xây dựng và đánh giá mô hình.

Để giải quyết đồng thời hai vấn đề trên, nghiên cứu đề xuất GeoFormerDock, một kiến trúc học sâu đa nhiệm [7] gọn nhẹ với 1.59 triệu tham số trên biểu diễn lưới voxel 3D [4]. Mô hình gồm một mạng cơ sở dùng chung và hai nhánh chuyên biệt: một nhánh khai thác đặc trưng hình học tường minh cho phân loại tư thế, nhánh còn lại sử dụng Transformer với cơ chế thiên vị chú ý theo khóa [8] cho dự đoán ái lực. Một chiến lược nhằm giảm ảnh hưởng của mất cân bằng lớp của dữ liệu được áp dụng cho nhánh phân loại tư thế. Chi tiết kiến trúc mô hình được trình bày ở Mục III. Kết quả thực nghiệm ở Mục IV cho thấy GeoFormerDock dẫn đầu về Balanced Accuracy và PR-AUC trong các mô hình so sánh, với quy mô tham số nhỏ hơn các kiến trúc CNN chuyên biệt, trong khi hiệu năng dự đoán ái lực vẫn còn khoảng cách với baseline mạnh nhất.

Để làm rõ vị trí của GeoFormerDock trong bối cảnh các hướng tiếp cận hiện có, nghiên cứu xây dựng một khung đánh giá chung cho bốn kiến trúc trên cùng biểu diễn voxel, cùng thiết lập huấn luyện và cùng bộ chỉ số. Khung này cho phép xem xét khách quan mức độ đánh đổi giữa khả năng phân loại tư thế và độ chính xác dự đoán ái lực, đồng thời tạo cơ sở thực nghiệm để so sánh GeoFormerDock với các kiến trúc khác trong cùng điều kiện dữ liệu và huấn luyện.

Nghiên cứu mang lại hai đóng góp cụ thể:

- 1) Đề xuất GeoFormerDock, một kiến trúc học sâu đa nhiệm gọn nhẹ kết hợp CNN 3D, đặc trưng hình học tường minh và cơ chế thiên vị chú ý theo khóa. Mô hình đạt vị trí không bị trội trên đường biên Pareto khi xét đồng thời hai nhiệm vụ và thể hiện ưu thế rõ rệt ở phân loại tư thể, trong khi số tham số nhỏ hơn đáng kể so với các kiến trúc CNN chuyên biệt mới nhất được so sánh.
- 2) Xây dựng khung benchmark chung cho bốn kiến trúc học sâu, cung cấp cơ sở thực nghiệm để định vị GeoFormerDock so với các hướng tiếp cận hiện có trong cùng điều kiện dữ liệu và huấn luyện.

II. NGHIÊN CỨU LIÊN QUAN

Các phương pháp truyền thống trong bài toán liên kết protein-phối tử chủ yếu dựa trên các thuật toán tìm kiếm không gian kết hợp với hàm chấm điểm để ước lượng năng lượng liên kết [1]. Mặc dù có ưu điểm về khả năng diễn giải dựa trên các nguyên lý vật lý, hóa học, các phương pháp này vẫn bộc lộ những hạn chế khi phải mô hình hóa sự biến đổi cấu dạng của protein, ảnh hưởng của dung môi và các tương tác phi tuyến phức tạp [2].

Sự phát triển của học sâu đã mở ra nhiều hướng tiếp cận mới cho bài toán này. Một trong những phương pháp phổ biến là sử dụng mạng nơ-ron tích chập 3D [3] trên biểu diễn dữ liệu dạng lưới voxel ba chiều [4], [3]. Các kiến trúc điển hình như GNINA [6] cho thấy khả năng khai thác hiệu quả các đặc trưng hình học cục bộ và tương tác trong vùng lân cận. Tuy nhiên, các mô hình 3D CNN thường tiêu tốn nhiều tài nguyên bộ nhớ khi tăng độ phân giải và gặp khó khăn trong việc mô hình hóa các phụ thuộc không gian ở khoảng cách xa.

Một hướng tiếp cận khác là sử dụng mạng nơ-ron đồ thị [9], trong đó cấu trúc phân tử được biểu diễn dưới dạng đồ thị với các đỉnh là nguyên tử và cạnh là các liên kết. Các mô hình như PotentialNet [10], EquiBind [11] và TankBind [12] đã cho thấy hiệu quả trong việc học biểu diễn cấu trúc và tương tác phân tử. Tuy nhiên, các kiến trúc đồ thị cơ bản thường thiếu khả năng khai thác trực tiếp ngữ cảnh không gian liên tục của vùng gắn kết nếu không được bổ sung các ràng buộc hình học chuyên biệt.


Gần đây, cơ chế chú ý và kiến trúc Transformer [8] đã được sử dụng để giải quyết bài toán phụ thuộc xa giữa các biểu diễn đặc trưng, cho phép mô hình hoá các quan hệ không gian toàn cục một

cách linh hoạt. Cùng với đó, học đa nhiệm [7] cũng trở thành một tiếp cận phù hợp khi các nhiệm vụ có liên quan được tối ưu đồng thời, chẳng hạn phân loại tư thể và dự đoán ái lực. Việc chia sẻ biểu diễn giữa các nhiệm vụ có thể giúp mô hình khai thác các đặc trưng chung, liên kết các tri thức tốt hơn và tận dụng sự tương đồng giữa các nhiệm vụ.

III. PHƯƠNG PHÁP NGHIÊN CỨU

A. Tiền xử lý và biểu diễn dữ liệu


Dữ liệu ban đầu được tổ chức dưới dạng tệp types chứa nhân tư thể, giá trị ái lực và đường dẫn tới cấu trúc của protein và phối tử [4]. Để gia tăng hiệu quả của mô hình, dữ liệu thuộc tập huấn luyện được tăng cường hình học thông qua các phép xoay ngẫu nhiên và dịch chuyển nhỏ trong không gian (tập kiểm tra không áp dụng tăng cường). Sau đó, mô-đun tạo lưới thực hiện chia lưới không gian vùng gắn kết với độ phân giải 0.5 Å.



Hình 1: Quy trình tiền xử lý và tạo lưới voxel cho dữ liệu phức hợp protein – phối tử.

Kết quả đầu ra của quy trình này là một lưới voxel có kích thước $48 \times 48 \times 48$, trong đó mỗi voxel được biểu diễn bởi 28 kênh đặc trưng mã hóa loại nguyên tử theo lược đồ atom-typing chuẩn của GNINA/libmolgrid (14 kênh cho protein, 14 kênh cho phối tử).

Mỗi mẫu mang hai loại nhãn riêng biệt: nhãn tư thể nhị phân $y_{pose} \in \{0, 1\}$ (tốt/xấu) và giá trị ái lực $y_{aff} \in \mathbb{R}$. Nhãn y_{pose} được xác định độc lập theo ngưỡng $RMSD \leq 2\text{Å}$ so với cấu trúc tham chiếu (cột RMSD trong tệp .types, quy ước gốc của CrossDocked2020/GNINA), với tỉ lệ dương thực tế là 12.4% trên tập huấn luyện và 13.5% trên tập kiểm tra. Theo quy ước của bộ dữ liệu, $y_{aff} > 0$ ứng với mẫu có ái lực thực nghiệm (đồng thời $y_{pose} = 1$), còn $y_{aff} \leq 0$ ứng với decoy; hai nhãn này không được dùng lẫn cho nhau ở bất kỳ bước huấn luyện/đánh giá nào - nhánh tư thể luôn dùng y_{pose} , nhánh ái lực luôn lọc theo dấu của y_{aff} (xem



Hình 2: Tổng quan kiến trúc mô hình học đa nhiệm GeoFormerDock.

mục hàm mất mát ái lực). Việc $y_{pose} = 1$ luôn trùng với $y_{aff} > 0$ không phải do gán nhãn chéo giữa hai tác vụ, mà do quy ước dấu: giá trị ái lực gốc chỉ giữ dương cho tư thế đúng (RMSD thấp) của phối tử thật và bị đảo dấu cho các tư thế/decoy còn lại - cùng một phức hợp có thể có cả tư thế tốt và xấu với cùng độ lớn ái lực nhưng khác dấu. Giá trị y_{aff} (trên tập con $y_{aff} > 0$) được chuẩn hóa theo phương pháp z-score trước khi đưa vào huấn luyện: $z = (y_{aff} - \mu)/\sigma$, với μ, σ ước lượng trên các nhãn ái lực dương của tập huấn luyện. Mạng được huấn luyện hoàn toàn trên thang chuẩn hóa này; khi đánh giá, dự đoán được đưa trở lại thang pK gốc trước khi tính các chỉ số.

B. Kiến trúc GeoFormerDock

GeoFormerDock được thiết kế theo nguyên lý học đa nhiệm [7], nhận đầu vào là lưới voxel và sử dụng một khối trích xuất đặc trưng dùng chung trước khi phân tách thành hai nhánh chuyên biệt để đánh giá tư thế và ái lực. Tổng quan kiến trúc của mô hình đề xuất được minh họa trong Hình 2, bao gồm mạng cơ sở dùng chung và hai nhánh học chuyên biệt được tối ưu hóa đồng thời.

1) *Khối trích xuất đặc trưng dùng chung*: Lưới voxel đi qua hai khối tích chập ba chiều duy trì tính tương biến theo phép tịnh tiến (translation equivariance) [3]: khối thứ nhất dùng bộ lọc $3 \times 3 \times 3$ (bước trượt $s = 1$, đệm $p = 1$, $28 \rightarrow 32$ kênh), khối thứ hai dùng bộ lọc $3 \times 3 \times 3$ (bước trượt $s = 2$, $32 \rightarrow 48$ kênh) để giảm chiều không gian, tiếp theo là một khối kết nối tắt dạng nhẹ [13] (hai lớp tích chập ba chiều kết hợp chuẩn hóa lô, một

đường nối tắt tích chập 1×1 để khớp số kênh, và một lớp phi tuyến ReLU sau phép cộng), cho ra $F_{shared} \in \mathbb{R}^{64 \times 24 \times 24 \times 24}$, đóng vai trò cung cấp ngữ cảnh chung cho cả hai nhiệm vụ phía sau (xem tổng quan trong Hình 2).

2) *Nhánh phân loại tư thế gắn kết*: Nhánh này giải quyết bài toán phân loại tư thế bằng cách hợp nhất thông tin từ hai luồng: đặc trưng cục bộ và đặc trưng hình học. Đối với luồng cục bộ, F_{shared} đi qua khối tích chập cục bộ (hai lớp Conv3D $3 \times 3 \times 3$ xen một phép max-pooling $2 \times 2 \times 2$, giảm lưới không gian từ 24^3 xuống 12^3) để tạo ra $F_{pose}^{(1)} \in \mathbb{R}^{64 \times 12 \times 12 \times 12}$, sau đó được rút trích thông qua phép gom cụm trung bình toàn cục và một mạng nơ-ron truyền thẳng để tạo ra vector h_{local} . Song song đó, luồng hình học chọn ra $K = 12$ voxel có chuẩn kênh lớn nhất trên chính $F_{pose}^{(1)}$ làm các điểm trọng yếu (pseudo-atom), thu được tọa độ chuẩn hóa $p_i \in [-1, 1]^3$ trên lưới cục bộ (không phải đơn vị Å) cùng vector đặc trưng kênh a_i tương ứng. Khoảng cách Euclid $d_{ij} = \|p_i - p_j\|_2$ giữa các cặp điểm được mã hóa qua $M = 16$ hàm cơ sở xuyên tâm (tâm và bề rộng là tham số học được):


$$\psi_{ij}^{(m)} = \exp\left(-\frac{(d_{ij} - \mu_m)^2}{2\sigma_m^2}\right) \quad (1)$$

Đặc trưng kênh trung bình và ma trận RBF trung bình theo cặp được nối và chiếu qua một lớp truyền thẳng để tạo ra vector hình học h_{geo} .

Hai luồng thông tin được hợp nhất thông qua cơ chế cổng thích nghi:

$$h_{fuse} = g \odot h_{local} + (1 - g) \odot h_{geo} \quad (2)$$

Sơ đồ luồng xử lý và cơ chế hợp nhất đặc trưng giữa tuyến cực bộ và tuyến hình học được mô tả trong Hình 3.



Hình 3: Kiến trúc nhánh phân loại tư thế gắn kết.

Kết quả cuối cùng đi qua lớp nơ-ron truyền thẳng và hàm softmax để đưa ra dự đoán nhị phân. Quá trình huấn luyện nhánh này sử dụng hàm mất mát tiêu điểm [14] nhằm xử lý dữ liệu mất cân bằng, với xác suất dự đoán của lớp đúng p_t , hệ số tập trung $\gamma = 2.0$ giảm mức độ phạt từ mẫu dễ, trọng số cân bằng $\alpha_t = \alpha = 0.75$ nếu $y_i = 1$, $\alpha_t = 1 - \alpha$ nếu $y_i = 0$ (ưu tiên lớp tư thế tốt):

$$\ell_i = \alpha_t (1 - p_t)^\gamma \mathcal{L}_{NLL}^{(i)} \quad (3)$$

Do dữ liệu mất cân bằng nghiêm trọng giữa hai lớp, tổn thất được gộp bằng *trung bình cân bằng theo lớp* thay vì trung bình đơn giản trên toàn batch:

$$\mathcal{L}_{pose} = \frac{1}{2} \left(\text{mean}_{i: y_i=0} \ell_i + \text{mean}_{i: y_i=1} \ell_i \right) \quad (4)$$

Đồng thời, trước khi tính $\mathcal{L}_{pose}$, một tập con 64 mẫu (32 tốt/32 xấu) được lấy mẫu lại có hoàn lại từ minibatch 1024 mẫu để duy trì tỉ lệ lớp cố định riêng cho hàm mất mát này. Đây là một yếu tố thuộc về thiết lập huấn luyện có ảnh hưởng trực tiếp tới Balanced Accuracy, cần được tách bạch khỏi đóng góp của kiến trúc mạng khi diễn giải kết quả.

3) *Nhánh dự đoán ái lực liên kết*: Nhiệm vụ hồi quy ái lực đòi hỏi mô hình nhận thức được bức tranh toàn cục của túi liên kết. Tương tự nhánh tư thế, đặc trưng chung được xử lý qua khối tích chập cực bộ (Conv3D xen max-pooling $2 \times 2 \times 2$, giảm 24^3 xuống 12^3) để sinh ra $F_{aff}^{(1)} \in \mathbb{R}^{64 \times 12 \times 12 \times 12}$. Từ tensor này, mô hình tạo ra vector h_{global} và chuyển đổi thành ma trận token $T \in \mathbb{R}^{N \times 128}$ với $N = 27$ (lưới token $3 \times 3 \times 3$, tương ứng chia $F_{aff}^{(1)}$ thành các patch kích thước 4 trên lưới cực bộ 12^3).

Ma trận token được đưa vào 2 khối Transformer [8] liên tiếp (embedding dim 128, tỉ lệ mở rộng MLP nội bộ là 2, dropout 0.1), trong đó cơ chế thiên vị chú ý theo khoá được thực hiện bằng


một cổng sigmoid sinh độ chệch chú ý từ nội dung của từng token khoá (key-saliency gating), áp dụng độc lập cho mỗi trong 4 head (chỉ số head được bỏ qua trong công thức dưới đây để gọn):

$$H = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_h}} + B_{pocket} \right) V \quad (5)$$

Trong đó, mỗi phần tử $[i, j]$ của ma trận độ chệch B_{pocket} cộng vào bên trong softmax ở Phương trình (5) được tính riêng cho từng head từ token khoá $\mathbf{x}_j \in \mathbb{R}^{128}$ (sau LayerNorm), với $\mathbf{w}, b$ là tham số riêng của head đó:

$$B_{pocket}[i, j] = \sigma(\mathbf{w}^\top \mathbf{x}_j + b) \quad (6)$$

Khác với các cơ chế thiên vị chú ý dựa trên khoảng cách không gian tường minh, B_{pocket} ở đây là độ chệch chú ý được sinh bởi một cổng sigmoid từ *nội dung* của token khoá j : nó không sử dụng bất kỳ tọa độ 3D nào, và chỉ phụ thuộc token khoá j - độc lập với token truy vấn i (do đó chỉ số i trong $[i, j]$ chỉ thể hiện việc bias này được cộng vào mọi hàng i của ma trận điểm số, không phải bias phụ thuộc cặp (i, j) thật). Bối cảnh túi liên kết vì vậy chỉ ảnh hưởng đến B_{pocket} một cách gián tiếp, thông qua việc mỗi token đã mang thông tin mật độ nguyên tử của vùng không gian nó phủ, chứ không qua ràng buộc hình học tường minh giữa các cặp token. Đặc trưng token sau đó được tổng hợp thành h_{token} .



Hình 4: Kiến trúc nhánh dự đoán ái lực liên kết.

Quá trình trích xuất, token hóa và tích hợp cơ chế cổng thiên vị chú ý theo khoá của nhánh hồi quy ái lực được minh họa trong Hình 4.

Hai vector h_{global} và h_{token} được gộp cổng để tạo thành h_{aff} , sau đó đi qua một lớp MLP, và giới hạn biên bằng τ_{clamp} (Bảng I) để cho ra $\hat{y}_{aff}$. Kiến trúc có kèm một phép hiệu chuẩn affine ($s \cdot \hat{y}_{aff} + b$) dành cho trường hợp huấn luyện trực tiếp trên thang pK gốc. Trong thiết lập thực nghiệm của bài báo (có chuẩn hóa z-score), $s = 1, b = 0$ được cố định nên không ảnh hưởng đến kết quả. Đây thuần túy là chi tiết cài đặt, không phải đóng góp kiến trúc.

Hàm mất mát của nhánh này là một tổ hợp đa mục tiêu nhằm điều tiết song song giá trị ái lực và quan hệ thứ tự:

$$\mathcal{L}_{aff} = \lambda_{reg}\mathcal{L}_{reg} + \lambda_{rank}\mathcal{L}_{rank} + \lambda_{dist}\mathcal{L}_{dist} + \lambda_{anchor}\mathcal{L}_{anchor} \quad (7)$$

Trong đó $\mathcal{L}_{reg}$ là hàm Huber ($\delta = 1.0$), giúp hồi quy bền vững trước ngoại lai:

$$\mathcal{L}_{reg}(y, \hat{y}) = \begin{cases} \frac{1}{2}(y - \hat{y})^2, & |y - \hat{y}| \leq \delta \\ \delta(|y - \hat{y}| - \frac{1}{2}\delta), & |y - \hat{y}| > \delta \end{cases} \quad (8)$$

$\mathcal{L}_{rank}$ tối ưu thứ tự tương đối theo cặp mẫu ngẫu nhiên trong batch ($|\mathcal{P}| = 128, \tau = 1.0$):

$$\mathcal{L}_{rank} = \frac{1}{|\mathcal{P}|} \sum_{(i,j) \in \mathcal{P}} \text{softplus} \left[-\text{sign}(y_i - y_j) \cdot \text{clamp} \left(\frac{\hat{y}_i - \hat{y}_j}{\tau}, -5, 5 \right) \right] \quad (9)$$

$\mathcal{L}_{dist}$ căn chỉnh kỳ vọng và độ lệch chuẩn giữa dự đoán và nhãn thật trong batch:

$$\mathcal{L}_{dist} = |\mu_{\hat{y}} - \mu_y| + |\sigma_{\hat{y}} - \sigma_y| \quad (10)$$

$\mathcal{L}_{anchor}$ dùng trung vị nhãn trong batch làm mốc neo, tránh suy biến dự đoán:

$$\mathcal{L}_{anchor} = |\hat{y} - \text{median}(y)| \quad (11)$$

Cả bốn thành phần chỉ được tính trên tập mẫu có nhãn ái lực dương ($y_{aff} > 0$) - các mẫu decoy không đóng góp gradient cho nhánh ái lực.

C. Tối ưu hóa đa nhiệm

Hàm mất mát tổng thể được định nghĩa bằng sự kết hợp tuyến tính có trọng số:

$$\mathcal{L}_{total} = w_{aff}\mathcal{L}_{aff} + w_{pose}\mathcal{L}_{pose} \quad (12)$$

Mạng được tối ưu hóa thông qua thuật toán AdamW [15] với tốc độ học 10^{-3} và hệ số điều chuẩn 10^{-2} . Chiến lược điều chỉnh tốc độ học theo hàm cosin kết hợp cùng hai epoch khởi động được áp dụng nhằm ổn định quá trình lan truyền gradient trong giai đoạn đầu huấn luyện.

Mô hình được đánh giá sau mỗi 2 epoch; checkpoint tốt nhất được lựa chọn theo chỉ số tổng hợp $0.5 \cdot \text{C-index} + 0.5 \cdot \text{Balanced Accuracy}$, với early stopping nếu 25 lần đánh giá liên tiếp không cải thiện chỉ số này. Trong lần chạy báo cáo, chỉ số tổng hợp vẫn còn cải thiện tới gần cuối nên early stopping không kích hoạt trước khi đạt số epoch tối đa (100).

Bảng I: Hệ số hàm mất mát và siêu tham số

Tham số	Giá trị
τ_{clamp} (thang z-score)	20
$\lambda_{reg}, \lambda_{rank}, \lambda_{dist}, \lambda_{anchor}$	1.0, 0.05, 0.02, 0.01
w_{pose}, w_{aff}	0.51, 0.15
Batch size (chuẩn)	1024

IV. THỰC NGHIỆM VÀ KẾT QUẢ

A. Dữ liệu

Thực nghiệm sử dụng tập CrossDocked2020 [4], chia theo split `ref_uff` do chính nhóm tác giả bộ dữ liệu công bố kèm bản phát hành (không phải bộ lọc tự chọn của nghiên cứu này): 62.335 mẫu huấn luyện và 4.618 mẫu kiểm tra, trong đó 623 mẫu (13.5%) có nhãn ái lực dương (mẫu thực nghiệm), số còn lại là decoy. Cả hai tập đều được chuyển thành lưới voxel $28 \times 48 \times 48$ với cùng quy trình mô tả ở Mục III.A; phép tăng cường (xoay ngẫu nhiên, tịnh tiến ± 1.0 Å) chỉ áp dụng cho tập huấn luyện.

B. Thiết lập thực nghiệm

Pafnucy và hai mô hình GNINA được cài đặt lại, huấn luyện từ đầu dưới cùng biểu diễn voxel 28×48^3 và cùng các siêu tham số tối ưu hóa chính (AdamW, 10^{-3} , 100 epoch, Mục III.C), nên số liệu phản ánh năng lực kiến trúc dưới điều kiện biểu diễn chung, không phải kết quả đã công bố nguyên bản. Hai mô hình GNINA dùng hàm hồi quy Gaussian NLL dị phương sai thay vì Huber, một khác biệt cần lưu ý khi diễn giải hiệu năng ở nhánh ái lực (Mục IV.D). Đối với nhánh phân loại tư thế của GeoFormerDock được huấn luyện với cân bằng lớp ở mức minibatch (32 mẫu tốt/32 mẫu xấu mỗi batch). Mô hình tốt nhất của mỗi kiến trúc được chọn theo chỉ số tổng hợp trên chính tập kiểm tra; một phép chọn đối chứng bằng chỉ số trên tập huấn luyện cho thứ hạng tương đối nhất quán giữa các mô hình.


C. Kết quả chính

Bảng II cho thấy GeoFormerDock dẫn đầu rõ rệt ở nhánh phân loại tư thế, còn ở nhánh ái lực khoảng cách với baseline không đồng đều giữa các mô hình. Xét theo từng lớp, GeoFormerDock đạt $R=-0.808$ (nhận diện tư thế nhiều), cao hơn so với GNINA-D18 (0.578) và Pafnucy (0.652), đối lại $R+=0.578$ giảm nhẹ so với hai mô hình này (0.945 và 0.928 tương ứng). Kết quả này phản ánh hiệu quả của cân bằng lớp ở mức minibatch (Mục IV.B) và cho thấy mô hình nhận diện đồng đều hơn thay vì thiên lệch về tư thế tốt như các baseline. So sánh cặp có kiểm định (paired bootstrap, $n = 2000, \alpha = 0.05$)

Bảng II: Kết quả đánh giá tổng hợp: phân loại tư thể gắn kết (I) và dự đoán ái lực liên kết (II). GNINA-D18/GNINA-Ds = GNINA Default2018/Dense; R+/R- = recall lớp tư thể tốt/xấu.

Mô hình	Params	I. Phân loại tư thể					II. Dự đoán ái lực				
		Acc	BalAcc	R+	R-	PR-AUC	MAE	RMSE	r	ρ	C-idx
GNINA-D18	2.16M	0.627	0.761	0.945	0.578	0.486	1.046	1.381	0.775	0.766	0.793
GNINA-Ds	0.46M	0.761	0.787	0.823	0.751	0.510	1.026	1.324	0.799	0.784	0.801
Pafnucy	7.99M	0.689	0.790	0.928	0.652	0.562	1.149	1.417	0.768	0.756	0.782
GeoFormerDock	1.59M	0.814	0.830	0.851	0.808	0.631	1.221	1.525	0.752	0.732	0.771


cho thấy GeoFormerDock so với GNINA Dense, mô hình dùng hàm hồi quy Gaussian NLL thay vì Huber như các mô hình còn lại, khác biệt có ý nghĩa thống kê trên cả 5 chỉ số; so với GNINA Default2018 và Pafnucy, khác biệt có ý nghĩa chủ yếu ở MAE/RMSE, trong khi Pearson/Spearman/C-index đều có khoảng tin cậy chứa 0, chưa đủ bằng chứng kết luận có khác biệt về các chỉ số tương quan và xếp hạng ái lực.



Hình 5: Đường cong Precision-Recall của tác vụ phân loại tư thể trên tập kiểm tra

Hình 5 cho thấy rõ hơn hình dạng đường cong đẳng sau chỉ số PR-AUC: GeoFormerDock dẫn đầu ở hầu hết dải recall, đặc biệt tại vùng recall thấp-trung bình nơi Precision thường sụt nhanh nhất do mất cân bằng lớp; bốn đường cong hội tụ gần nhau ở recall cao, cho thấy khác biệt giữa các mô hình chủ yếu nằm ở khả năng xếp hạng các mẫu để phân biệt hơn là các mẫu khó nhất. So sánh cặp có kiểm định (paired bootstrap, $n = 2000$, $\alpha = 0.05$, toàn bộ 4.618 mẫu kiểm tra) cho thấy GeoFormerDock vượt trội có ý nghĩa thống kê so với cả ba baseline trên cả Balanced Accuracy (chênh lệch trung bình +0.040 đến +0.068) và PR-AUC (chênh lệch trung bình +0.068 đến +0.144), khoảng tin cậy 95% không chứa 0 ở toàn bộ 6 phép so sánh.

D. Phân tích đánh đổi



Hình 6: Đường biên Pareto giữa Balanced Accuracy (phân loại tư thể) và MAE (dự đoán ái lực) trên các mô hình so sánh.

Hình 6 thể hiện vị trí tương đối của các mô hình trên hai mục tiêu. GeoFormerDock nằm ở cực ưu tiên phân loại tư thể, trong khi nhóm GNINA nằm ở cực ưu tiên ái lực; không mô hình nào chiếm ưu thế tuyệt đối trên cả hai trục. Đây là quan sát trên 4 điểm rời rạc chứ không phải một đường cong đánh đổi liên tục (đòi hỏi quét trọng số w_{pose}/w_{aff} cho từng kiến trúc) - với chỉ 4 mô hình, việc không bị trội tuyệt đối là điều kiện dễ đạt về mặt toán học (bất kỳ mô hình nào tốt nhất ở một trục đều tự động thỏa điều kiện này), nên hiểu đây là quan sát định tính về vị trí tương đối, không phải một đường biên Pareto đầy đủ. Vị trí cụ thể của mỗi mô hình trên mặt phẳng đánh đổi không chỉ do kiến trúc quyết định: như đã nêu ở Mục IV.B, khác biệt về hàm mất mát (Gaussian NLL so với Huber) và về cân bằng lớp ở mức minibatch cũng góp phần định hình kết quả quan sát được. Với quy mô tham số nhỏ hơn 1–5 lần so với Pafnucy và GNINA Default2018, GeoFormerDock vẫn đạt Balanced Accuracy cao nhất - cho thấy sự đánh đổi này không đơn thuần là hệ quả của thiếu năng lực mô hình.

V. KẾT LUẬN

Nghiên cứu đề xuất GeoFormerDock, một kiến trúc học sâu đa nhiệm gọn nhẹ (1.59 triệu tham số) cho bài toán phân loại tư thể gắn kết và dự đoán ái lực protein-phối tử. Trên khung đánh giá chung xây dựng cho bốn kiến trúc, GeoFormerDock đạt vị trí không bị trội trên đường biên Pareto giữa hai nhiệm vụ, dẫn đầu về Balanced Accuracy và PR-AUC ở nhánh phân loại tư thể với quy mô tham số nhỏ hơn đáng kể so với các kiến trúc CNN chuyên biệt, trong khi vẫn còn khoảng cách có ý nghĩa thống kê với GNINA Dense ở nhánh ái lực (riêng với GNINA Default2018 và Pafnucy, khác biệt chỉ rõ ràng ở MAE/RMSE).

Một số điểm cần lưu ý khi diễn giải các kết quả trên: (i) checkpoint tốt nhất và điểm dừng sớm hiện được chọn trên chính tập kiểm tra do chưa có tập validation độc lập; giữa hai epoch liên tiếp (98 và 100), Balanced Accuracy đo được dao động tới 0.163, một mức chênh lệch đáng cân nhắc khi diễn giải kết quả; (ii) các số liệu hiện dựa trên một lần chia train/test, chưa có điều kiện chạy lặp lại hay chia theo cluster protein/pocket để đánh giá đầy đủ hơn khả năng tổng quát hóa; (iii) nhóm mô hình đồ thị (PotentialNet, EquiBind, TankBind) không được đưa vào so sánh vì hoạt động trên biểu diễn đồ thị nguyên tử, không tương thích với khung voxel thống nhất của nghiên cứu này; so sánh chéo giữa hai họ biểu diễn đòi hỏi thiết kế thực nghiệm riêng; (iv) các chỉ số ái lực được tính trên 623/4.618 mẫu có nhân ái lực dương; (v) việc tách bạch đóng góp của kiến trúc so với các yếu tố huấn luyện (hàm mất mát, cân bằng lớp ở mức minibatch) vẫn là hướng cần làm rõ thêm.

TÀI LIỆU

- [1] S. S. Dhillon, H. Singh, and R. Kaur, "Molecular docking in the era of artificial intelligence and machine learning: A comprehensive review," *Computer Methods and Programs in Biomedicine*, vol. 244, p. 107950, 2024.
- [2] Y. Li, S. Zhang, and R. Wang, "Deep learning for structure-based drug design: State-of-the-art and future directions," *Journal of Chemical Information and Modeling*, vol. 64, no. 3, pp. 685–704, 2024.
- [3] M. Ragoza, J. Hochuli, E. S. Idrobo, J. Sunseri, and D. R. Koes, "Protein-ligand scoring with convolutional neural networks," *Journal of Chemical Information and Modeling*, vol. 57, no. 4, pp. 942–957, 2017.
- [4] P. G. Francoeur, T. Masuda, J. Sunseri, A. Jia, R. B. Iovanisci, I. Snyder, and D. R. Koes, "Three-dimensional convolutional neural networks and a cross-docked data set for structure-based drug design," *Journal of Chemical Information and Modeling*, vol. 60, no. 9, pp. 4200–4215, 2020.
- [5] M. M. Stepniewska-Dziubinska, P. Zielenkiewicz, and P. Siedlecki, "Development and evaluation of a deep learning model for protein-ligand binding affinity prediction," *Bioinformatics*, vol. 34, no. 21, pp. 3666–3674, 2018.
- [6] A. T. McNutt, P. Francoeur, R. Aggarwal, T. Masuda, R. Meli, M. Ragoza, J. Sunseri, and D. R. Koes, "Gnina 1.0: molecular docking with deep learning," *Journal of Cheminformatics*, vol. 13, no. 1, p. 43, 2021.
- [7] R. Caruana, "Multitask learning," *Machine Learning*, vol. 28, no. 1, pp. 41–75, 1997.
- [8] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Lukasz. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [9] X. Tang, J. Wang, S. Yoon, and Q. Liu, "Deep learning in bioinformatics: review, challenges, and perspectives," *Briefings in Bioinformatics*, vol. 26, no. 1, p. bbae612, 2025.
- [10] E. N. Feinberg, D. Sur, Z. Wu, B. E. Husic, H. Mai, Y. Li, S. Sun, J. Yang, B. Ramsundar, and V. S. Pande, "Potentialnet for molecular property prediction," *ACS Central Science*, vol. 4, no. 11, pp. 1520–1530, 2018.
- [11] H. Stark, O. Ganea, L. Pattanaik, R. Barzilay, and T. Jaakkola, "Equibind: Geometric deep learning for drug binding structure prediction," in *International Conference on Machine Learning (ICML)*, 2022.
- [12] W. Lu, Q. Wu, J. Zhang, J. Rao, C. Li, and S. Zheng, "Tankbind: Trigonometry-aware neural networks for drug-protein binding structure prediction," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, 2022, pp. 7236–7249.
- [13] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.
- [14] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal loss for dense object detection," in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017, pp. 2980–2988.
- [15] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," *arXiv preprint arXiv:1711.05101*, 2017.